

基于 EEG 的脑卒中患者运动想象

摘要

基于脑电图 (EEG) 的运动想象研究为脑卒中患者的康复提供了一种非侵入式且有效的技术手段。脑卒中通常导致患者出现运动功能障碍，而运动想象分类技术通过分析患者的 EEG 信号，解码其运动意图，从而促进神经重塑并辅助康复训练。本文旨在复现一项已有的研究，该研究采用传统的机器学习方法—Fisher 判别几何过滤与黎曼均值分类方法 (DGFMDM) 对脑卒中患者运动想象 EEG 信号进行分类。尽管传统方法在特定条件下表现出较好的分类性能，但由于其在处理高维脑电信号时存在一定局限性，如对特征工程的强依赖以及泛化能力的限制。因此，本文尝试引入深度学习方法，采用连续卷积神经网络 (CCNN) 模型，在公开的脑卒中 EEG 数据集上进行运动想象分类实验。结果表明，CCNN 模型不仅取得了较为理想的分类准确率，还展现出自动特征提取的显著优势，有效减少了人工特征工程的依赖。实验验证了深度学习在复杂脑电信号处理中的应用潜力，并为后续方法改进和应用研究奠定了基础。

关键词：EEG；运动想象；特征提取；分类

1 引言

脑卒中是一种严重威胁全球公共健康的神经系统疾病，其后遗症通常表现为偏瘫、肢体运动障碍等。这些功能障碍严重影响患者的日常生活能力和生活质量。传统的康复手段主要通过让患者进行重复的物理康复训练，通过频繁的肢体动作强化受损脑部区域的神经通路的重塑。然而，这种方法存在显著局限性，康复训练过程枯燥，患者易产生疲劳或抵触情绪；对于重度瘫痪的患者，由于无法进行有效运动，康复效果更为有限。此外，这种康复手段依赖专业人员的指导，周期长、成本高，对康复资源不足的地区尤为不利。

近年来，脑机接口技术在神经康复领域展现出强大的潜力，尤其是基于运动想象的脑机接口。运动想象是指患者通过大脑想象肢体运动，从而激活与实际运动相关的脑区活动。这一过程无需肢体动作，对于瘫痪患者来说是一种突破性的康复方式。通过脑电图记录运动想象时的大脑活动，基于 EEG 的 BCI 能够识别运动意图并实时反馈，进而促进大脑神经网络的重塑。神经可塑性是大脑重建神经元间连接的能力 [9]，有助于建立其他神经通路来补偿脑卒中造成的脑损伤 [5]。上肢功能对日常活动较大，且恢复上肢功能对患者生活质量的改善至关重要。因此，研究和康复计划常常将上肢功能恢复作为首要目标。相比传统康复手段，EEG 技术具备诸多优势，如设备便携、数据采集简单，成本较低，适合长期监测和训练。然而，脑卒中患者的 EEG 信号通常因神经网络受损而具有低信噪比，信号稳定性较差，导致运动想象分类的准确性面临挑战。此外，由于患者间的脑电特征差异显著，现有算法在跨患者的样本

分类的泛化能力上表现不足。这些问题限制了基于 EEG 的运动想象 BCI 在脑卒中康复中的实际应用。传统的信号处理方法，如时域、频域和时频域分析，虽取得了一定的成功，但在处理复杂的 EEG 信号时，常常存在提取特征不足、分类效果不理想等问题。近年来，卷积神经网络因其在图像识别领域的卓越表现，逐渐被应用于 EEG 信号分析。因此，为了提高脑卒中患者运动想象分类的精度，本研究使用连续卷积神经网络模型的方法，分类经过特殊构建的 3D 脑电立方体，这不仅保留了信号的时域和频域特征，还能够在三维空间中捕捉到信号的局部空间结构。

2 相关工作

2.1 EEG 信号特征提取方法

EEG 信号具有高度的噪声和个体差异，因此，如何从原始 EEG 信号中提取有用的特征是运动想象分类中的关键步骤。传统的特征提取方法通常分为时域特征、频域特征和时频域特征，这些方法在运动想象任务中得到了广泛应用。

CSP [8] 是 EEG 信号处理中最常用的空间特征提取方法之一，尤其在运动想象分类任务中被广泛应用。CSP 通过提取与不同脑电活动（如运动和静息状态）相关的空间模式，将脑电图信号转换为具有最大区分度的特征空间。特别是运动想象任务，CSP 能有效区分运动想象信号与静息状态下的 EEG 信号。许多研究表明，CSP 能有效提升运动想象任务的分类性能，尤其是在低维度 EEG 信号下，能够最大化类间方差并减少类内方差。然而，CSP 面临的问题是对噪声的敏感性和个体差异性，尤其是在脑卒中等患者的信号中，CSP 可能因个体差异而表现不稳定。

FBCSP [1] 是 CSP 的扩展，结合了多频带滤波和 CSP 特征提取。FBCSP 通过将 EEG 信号分解成多个频带，并分别对每个频带应用 CSP，能够更全面地捕捉 EEG 信号中的多维特征。不同频段的 EEG 信号与运动想象有不同的相关性，因此 FBCSP 通过多频带分析能更好地提取运动想象的信号特征。FBCSP 在运动想象 EEG 分类中具有很好的应用前景，尤其适用于多通道 EEG 信号的特征提取。研究表明，FBCSP 能够有效提高 EEG 信号分类的精度，尤其是在运动想象任务中。通过多频带处理，FBCSP 可以捕捉更多的频率特征，增强运动想象信号的区分性。

2.2 运动想象 EEG 信号分类方法

传统机器学习算法通过对提取的特征进行分类，来实现运动想象信号的分类任务。常用的分类算法主要包括 SVM [7]、LDA [4] 等。

SVM 是应用最广泛的传统机器学习分类算法之一。SVM 具有良好的性能，尤其在高维数据、非线性分类任务中表现突出。SVM 通过构造一个超平面，将不同类别的样本最大化分开，能够有效地进行小样本学习。许多基于 EEG 的运动想象研究采用 SVM 作为分类器，尤其是结合了 CSP 等特征提取方法后，能够提高分类精度和鲁棒性。

LDA 是另一种广泛应用于 EEG 分类中的经典算法，尤其适用于线性可分问题。LDA 通过寻找最大化类间散度与最小化类内散度的投影方向来进行分类。LDA 的计算简单、易于实现，且在某些低维问题中效果良好，尤其是在 CSP 提取特征后，LDA 通常能够获得较高的

分类性能。尽管传统机器学习方法在基于 EEG 的运动想象分类中取得了显著进展，但仍然面临一些挑战。EEG 信号受噪声影响较大，个体之间的 EEG 差异使得跨患者的分类准确性难以保证。因此，结合深度学习与传统机器学习方法、跨领域迁移学习、个性化调整等技术，将为 EEG 信号的运动想象分类提供更强大的工具，推动脑卒中患者运动康复的研究与应用。

3 本文方法

文章提出了一种基于脑电图（EEG）信号的运动想象分类方法，主要通过以下几个关键步骤完成整个任务：特征提取、特征降维、分类。通过有效地捕捉和分析脑电信号中的特征，利用传统的分类方法对脑卒中患者的运动想象进行分类。

3.1 特征提取

3.1.1 时间窗口与滤波器组划分

为了有效捕捉脑电信号中的瞬态变化和动态特征，文章采用了滑动时间窗口技术对 EEG 信号进行分割。时间窗口长度设置为 1 秒，滑动步长为 0.5 秒。通过这种方式，原始信号被划分为多个短时间段，能够有效地减少信号的冗余信息，并提高后续分析步骤中对短期动态变化的敏感性。此外，通过采用滑动窗口技术，可以确保信号的连续性，进一步增强模型对时间序列特征的捕捉能力。

在频率域上进行信号分解是另一个重要的预处理步骤。EEG 信号可以根据其频率特征分解为不同的频段。这些频段代表了大脑活动的不同模式，每种波段都与大脑的不同生理和认知状态相关，主要分为 σ 波、 θ 波、 α 波、 β 波以及 γ 波。具体的频段的频率范围以及特点如表1所示。

表 1. EEG 信号频段的频率范围以及特点

频率模式	频率范围	特点
σ 波	0.5-4 Hz	最低频率的脑电波；通常出现在深度睡眠或昏迷状态
θ 波	4-8 Hz	常见于轻度睡眠、放松或冥想状态
α 波	8-13 Hz	通常出现在清醒、放松但警觉的状态下，如闭眼放松
β 波	13-30 Hz	常见于紧张、高强度的精神活动状态
γ 波	30-100 Hz	最高频率的脑电波，与高级认知功能、感知处理、注意力等有关

在运动想象任务中，大脑在特定频段内的活动与运动意图的产生密切相关。例如， α 波 (8-13 Hz) 通常与静息状态下的放松和静止相关，但在运动想象过程中， α 波的活动会发生显著变化，尤其是在运动准备阶段， α 波的抑制现象常常表明运动意图的启动。这一抑制现象被认为是运动想象过程中的一种重要标志。而 β 波 (13-30 Hz) 则与运动相关的脑区活动密切相关，尤其在运动想象期间， β 波的增强常常被用来指示运动意图的出现和运动执行准备。

为了有效捕捉 EEG 信号中的细微变化，设计了多个滤波器组，以精确提取不同频段的信号成分。每个滤波器组的频段相较于前一个具有一定的频率偏移，从而覆盖更细粒度的频率范围，进一步提高了特征提取的灵敏度。滤波器的频率范围从低频的 8 Hz 至高频的 30 Hz，滤波器组覆盖了若干频段（例如，8-12 Hz, 9-13 Hz, 10-14 Hz 等）。通过这种方式，能够提取

EEG 信号在不同频率范围内的特征，进一步帮助分析 EEG 信号中与运动想象任务相关的频率活动模式。滤波器组的设计不仅能够捕捉 EEG 信号的频率成分，还能够有效地揭示与运动想象过程中大脑活动相关的关键变化，从而为后续的信号分类和识别提供更为精准的特征支持。

3.1.2 时间窗口与滤波器组选择

为了选择最优的时间窗口与频率带组合，以确保后续特征提取和分类的准确性，本文采用回溯搜索优化算法 [2] (Backtracking Search Optimization Algorithm, BSA)。该方法能够在全局搜索空间内找到具有最强区分能力的时间和频率窗口组合，从而为分类任务提供更具代表性的特征。

1. 初始化种群：随机生成一个包含 N 个个体的初始种群，每个个体表示为一个解向量 $x_i = [t_i, f_i]$ ，其中 t_i 和 f_i 分别代表时间窗口和频率带的组合。
2. 变异操作：在种群中随机选择若干个个体，对其解向量进行变异操作生成变异解。具体地，对于个体 x_i ，变异生成的新个体 v_i 计算如下：

$$v_i = x_i + F \cdot (x_r - x_s),$$

其中 F 为缩放因子， x_r 和 x_s 是从种群中随机选择的两个不同个体。

3. 交叉操作：将当前种群与前一代种群进行交叉组合，以引入多样性，增加搜索到全局最优解的可能性。交叉后的个体 u_i 通过以下方式生成：

$$u_i[j] = \begin{cases} v_i[j], & \text{如果 } rand[j] \leq CR, \\ x_i[j], & \text{否则.} \end{cases}$$

其中 CR 为交叉概率， $rand[j]$ 是在 $[0, 1]$ 间均匀分布的随机数。

4. 选择操作：计算每个解向量的适应度值 $F(x_i)$ ，以分类准确率作为适应度的评估标准。对于当前种群的每个个体 x_i 和对应的变异个体 u_i ，选择适应度值较高的个体进入下一代种群：

$$x'_i = \begin{cases} u_i, & \text{如果 } F(u_i) > F(x_i), \\ x_i, & \text{否则.} \end{cases}$$

5. 终止条件：设置终止条件，如最大迭代次数 T_{max} 或适应度值达到预设阈值 F_{thres} 。当满足条件时，停止迭代，并输出当前种群中适应度值最高的个体 x^* ，其对应的时间窗口与频率带组合即为最优解。

3.1.3 计算协方差矩阵

选择的最优时间窗口和频率窗口之后，计算 EEG 信号的协方差矩阵，以表征信号的时空特性，为后续的特征分析提供基础。设 $\mathbf{X} \in \mathbb{R}^{C \times T}$ 表示一个时间窗口内的 EEG 数据片段，其中 C 为通道数量， T 为时间采样点数，则协方差矩阵的计算公式为：

$$\mathbf{C} = \frac{1}{T-1} (\mathbf{X} - \mathbf{X})(\mathbf{X} - \mathbf{X})^\top,$$

其中, $\mathbf{X} \in \mathbb{R}^{C \times T}$ 表示 \mathbf{X} 中的均值矩阵, 其第 i -行元素为该通道的均值, 具体为:

$$\mathbf{X}_{i,t} = \frac{1}{T} \sum_{t=1}^T \mathbf{X}_{i,t}, \quad i = 1, 2, \dots, C.$$

在所有最优时间窗口和频率窗口内, 计算出的协方差矩阵将构成一个集合:

$$\mathcal{C} = \{\mathbf{C}_1, \mathbf{C}_2, \dots, \mathbf{C}_N\},$$

其中 N 为最优时间窗口和频率窗口组合的数量, \mathbf{C}_i 为第 i 个组合下计算得到的协方差矩阵。

协方差矩阵集合 \mathcal{C} 能有效捕捉 EEG 信号的时空特性, 为后续的特征降维和分类步骤提供丰富的特征表征信息。

3.1.4 特征降维

为了降低协方差矩阵集的维度, 同时保留其几何结构特性, 本文采用局部切空间排列算法 [11] (Local Tangent Space Alignment, LTSA) 对协方差矩阵集 $\mathcal{C} = \{\mathbf{C}_1, \mathbf{C}_2, \dots, \mathbf{C}_N\}$ 进行降维处理。LTSA 能够将高维协方差矩阵映射到低维空间, 有效减少计算复杂度并提升分类效率。

LTSA 算法的核心思想是利用数据的局部线性结构, 构造切空间并将其对齐, 以实现全局低维嵌入。具体步骤如下:

1. 邻域选择: 对于每个协方差矩阵 \mathbf{C}_i , 选择其 k 个最近邻数据点 $\{\mathbf{C}_{i_1}, \mathbf{C}_{i_2}, \dots, \mathbf{C}_{i_k}\}$, 以构造局部邻域。
2. 切空间构造: 在局部邻域内, 通过对协方差矩阵进行主成分分析 (PCA), 获取局部切空间的基向量 $\mathbf{U}_i \in \mathbb{R}^{d \times D}$, 其中 d 为降维后的目标维度, D 为原始协方差矩阵的维度。
3. 局部重构权重计算: 对每个数据点 \mathbf{C}_i , 计算其在局部邻域中被重构的误差最小化问题, 定义如下:

$$\min_{\mathbf{W}_i} \left\| \mathbf{C}_i - \sum_{j=1}^k w_{ij} \mathbf{C}_{i_j} \right\|_F^2,$$

其中, $\mathbf{W}_i = [w_{i1}, w_{i2}, \dots, w_{ik}]^\top$ 为重构权重, $\|\cdot\|_F$ 表示 Frobenius 范数。

4. 全局对齐与降维映射: 通过将所有局部切空间对齐, 构造全局嵌入目标函数, 形式为:

$$\min_{\mathbf{Y}} \sum_{i=1}^N \left\| \mathbf{Y}_i - \sum_{j=1}^k w_{ij} \mathbf{Y}_{i_j} \right\|_F^2,$$

其中, $\mathbf{Y}_i \in \mathbb{R}^d$ 是低维空间中协方差矩阵 \mathbf{C}_i 的映射表示。

经过 LTSA 降维后的协方差矩阵集 $\mathcal{Y} = \{\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_N\}$ 保留了原始数据的几何结构特性, 为后续分类步骤提供更加紧凑和有效的特征表示。

3.2 分类方法

将经过 LTSA 降维处理后的特征矩阵集合 $\mathcal{Y} = \{\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_N\}$ 输入到判别几何滤波器 [3] (Discriminant Geometry Filter, DGF) 中进行进一步处理。判别几何滤波器利用协方差矩阵的黎曼几何特性，通过优化信号的区分性增强分类性能。

判别几何滤波器的核心思想是在黎曼流形上重新分布协方差矩阵，使得类内差异最小化，同时类间差异最大化。定义优化目标如下：

$$\mathcal{L} = \sum_{i,j \in \text{same class}} d_{\mathcal{R}}(\mathbf{Y}_i, \mathbf{Y}_j)^2 - \lambda \sum_{i,j \in \text{different class}} d_{\mathcal{R}}(\mathbf{Y}_i, \mathbf{Y}_j)^2,$$

其中， $d_{\mathcal{R}}(\cdot, \cdot)$ 表示黎曼流形上的几何距离， λ 为正则化参数，用于权衡类内和类间的权重。

经过判别几何滤波器调整后的特征矩阵 $\mathcal{Y}' = \{\mathbf{Y}'_1, \mathbf{Y}'_2, \dots, \mathbf{Y}'_N\}$ 被输入到黎曼最小距离分类器 (Riemannian Minimum Distance to Mean, MDRM) 中。MDRM 分类器基于黎曼均值 $\bar{\mathbf{Y}}_c$ 进行决策，定义如下：

$$\bar{\mathbf{Y}}_c = \mathbf{Y} \sum_{\mathbf{Y}_i \in \text{class } c} d_{\mathcal{R}}(\mathbf{Y}, \mathbf{Y}_i)^2,$$

其中， \mathbf{Y}_i 为类别 c 中的样本， $\bar{\mathbf{Y}}_c$ 为类别 c 的黎曼均值。

分类时，对于任意样本 \mathbf{Y} ，其预测类别 \hat{c} 定义为：

$$\hat{c} = \arg \min_c d_{\mathcal{R}}(\mathbf{Y}, \bar{\mathbf{Y}}_c).$$

通过这种结合判别几何滤波器和黎曼最小距离分类器的策略，可以充分利用协方差矩阵的几何特性，实现对运动想象任务的稳健识别。

4 复现细节

4.1 与已有开源代码对比

在本研究中，首先使用了开源的 MATLAB 代码实现了 DGFMDM 方法进行脑卒中患者运动想象 EEG 信号的分类。尽管 DGFMDM 方法在某些任务中已被证明具有较好的效果，但它在处理高维和复杂数据时，面临着特征工程强依赖和局限性，特别是在处理 EEG 信号的非线性和高维特性时，可能会忽略某些潜在的模式。

为了克服这些局限，本研究采用了连续卷积神经网络 (CCNN) 模型 [10]，这一方法已在许多研究中成功应用于 EEG 信号的分类任务。与 DGFMDM 方法不同，CCNN 通过深度学习自动提取特征，能够更好地捕捉 EEG 信号中的复杂非线性关系。特别是在运动想象任务中，CCNN 能够通过多层卷积层处理 EEG 信号的时空特性，而无需人工设计特征。这一优势使得 CCNN 能够有效地从复杂的 EEG 数据中学习深层次的时空信息，提升分类性能，并减少了对人工特征选择的依赖。

在本文的实验中，我们将协方差矩阵作为输入数据进行处理。协方差矩阵能够捕捉信号中的空间和时域依赖关系，并能够有效表示不同脑区之间的相互作用，尤其适用于分析脑电信号的复杂结构。为了将协方差矩阵输入到 CCNN 模型中，我们首先通过传统的 EEG 信号

预处理步骤（如去伪迹、滤波等）获得每个波段的协方差矩阵，并将其作为输入传递到网络中。这种方法避免了人工设计特征的繁琐过程，能够直接利用 EEG 信号中的固有模式。

该网络包含四个卷积层，从输入的 EEG 的三维数据中提取特征。卷积层之后有一个全连接层进行特征融合，并使用了 dropout 操作，最后通过 softmax 层进行分类。CCNN 模型的总体架构如图 2 所示。在前三个卷积层中，使用了 4×4 的卷积核，步长为 1，并在每个卷积层后应用了 RELU 激活函数，以引入非线性特征变换。第一层使用了 64 个特征图，在接下来的两层中，特征图的数量分别增加到 128 和 256。为了减少计算量并融合特征，后续是一个 1×1 的卷积层，设定 64 个特征图。经过这四个连续的卷积层后，使用了一个全连接层，将 $64 \times 9 \times 9$ 的特征图映射为 1024 维度的特征向量，使用 softmax 层接受特征向量进行分类。模型架构如图 1 所示：




图 1. CCNN 模型架构图 [10]

4.2 实验环境设置

本研究中，实验环境的软硬件配置如下。在传统方法的实现中，使用了 MATLAB R2023a 版本完成了 TWFB+DGFMDM 方法的复现和相关实验；在深度学习模型 CCNN 的实验中，使用了 Python 3.8 作为主要开发语言，并基于 PyTorch 框架进行模型构建和训练。

硬件环境方面，实验在一台搭载 NVIDIA GeForce RTX 3090 GPU 的计算机上进行，显存为 24 GB，处理器主频 2.80 GHz，最大频率 3.60 GHz。GPU 提供了强大的并行计算能力，有效加速了深度学习模型的训练过程。此外，实验所用操作系统为 Linux。

为了确保实验的可复现性和稳定性，深度学习模型的随机种子被设置为固定值，并通过使用 CUDA 工具加速 GPU 运算。训练过程中采用了 Adam 优化器，学习率设置为 0.001，并根据动态调整学习率。

5 实验结果分析

5.1 数据集

本研究使用的数据集来源于论文 [6] 公开的脑卒中患者运动想象实验数据。该数据集包含 50 名脑卒中患者在运动想象任务中的脑电信号 (EEG) 数据，实验通过 10-10 EEG 电极系统进行脑电信号采集，采样频率为 500Hz。每位患者佩戴电极帽，根据眼前屏幕和声音指令进行左右手抓握的运动想象。每次指令持续 2 秒，运动想象阶段为 4 秒，随后的休息时间

为 2 秒。每位患者重复进行 40 次试验，数据采集过程中，特别关注与运动想象相关的脑功能活动，尤其是运动皮层、额叶、顶叶等关键脑区的电活动变化。

数据集包含 50 名患者的 40 次实验数据，每次实验的时长为 8 秒。每个试验周期内，收集了 32 个通道的数据，包括 29 个 EEG 信号通道、2 个眼动电图（EOG）信号通道和 1 个事件标记通道。这些数据为分析脑卒中患者在运动想象任务中的脑电信号特征提供了重要的信息。

5.2 评估指标

准确率是最常用的分类评估指标之一，能够反映模型在所有样本上的整体预测能力。其定义为模型正确预测的样本数与总样本数之比，并以百分比表示。其数学表达式为：

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Samples}} \times 100\%$$

其中, Number of Correct Predictions 表示模型正确预测的样本数, Total Number of Samples 表示数据集中的总样本数。较高的准确率意味着模型在总体样本中的分类效果较好。

5.3 实验结果

本文的实验结果如表 2 所示，分别展示了不同方法在脑卒中患者运动想象 EEG 信号分类任务中的分类准确率。通过分析可以发现，传统方法和深度学习方法在分类性能上的差异反映了各自的优势与不足。

表 2. 分类结果

方法	分类准确率
TWFB+DGFMDM (论文)	72.21%
TWFB+DGFMDM (复现)	65.61%
CCNN	60.24%

TWFB+DGFMDM 方法在原论文中进行分类的准确率达到 72.21%。这一结果表明，DGFMDM 方法在处理脑卒中患者运动想象 EEG 信号时，能够充分利用协方差矩阵的几何特性。其分类效果较优的原因在于黎曼几何理论的引入，使得该方法在挖掘协方差矩阵的内在特性时更为精确。然而，该方法对特征工程的依赖较高，且在实际应用中，由于 EEG 信号的复杂性和高维特性，其对不同数据分布的泛化能力可能受到一定限制。

在复现实验中，使用开源的 MATLAB 代码对 TWFB+DGFMDM 方法进行了实现，得到的分类准确率为 65.61%。这一结果低于原论文中的报告准确率 (72.21%)，可能原因包括实验环境的差异、随机划分数据集的不同，以及复现过程中对数据预处理的不一致性。这说明，TWFB+DGFMDM 方法的性能在一定程度上对实验细节较为敏感，特别是数据的划分和模型的训练设置。此外，复现过程中可能存在对某些实验细节的忽视，进一步影响了模型表现。

本文尝试将协方差矩阵输入连续卷积神经网络 (CCNN)，以探索深度学习方法在处理运动想象 EEG 信号中的潜力。实验结果表明，CCNN 模型的分类准确率为 60.24%，低于 TWFB+DGFMDM 方法。这可能是由于协方差矩阵属于非欧几里得空间，而传统的 CNN 模

型在直接处理非欧几里得数据时存在局限性，未能有效解析协方差矩阵的几何特性。此外，使用的数据集的数据量不大，CCNN 模型在训练过程中面临数据量不足的问题，这可能导致模型的泛化能力受到限制。尽管如此，CCNN 模型仍具备一定的自动化特征提取能力，在减少人工干预方面具有优势，为未来的改进提供了可能性。

6 总结与展望

本文复现了传统方法 TWFB+DGFMDM，并将深度学习模型 CCNN 应用于脑卒中患者运动想象 EEG 信号分类任务。在实验中，TWFB+DGFMDM 方法表现出了较高的分类准确率，而 CCNN 模型虽然在分类准确率上逊色，但具有减少特征工程依赖的潜在优势。总体来看，两种方法各有特点，传统方法能够利用几何特性挖掘协方差矩阵的潜在模式，而深度学习方法则在自动化和灵活性方面表现出色。

未来研究可以从以下几个方面进一步优化。首先，为更好地处理协方差矩阵的几何特性，可以引入 Log-Euclidean 映射或其他几何工具，将非欧几里得数据转换为欧几里得空间表示，从而提高深度学习模型的适配性。其次，设计更适合协方差矩阵的深度学习架构，如基于对称正定矩阵的网络，可能有效提升模型的性能。此外，研究可扩展的训练策略，如增加训练数据规模、应用数据增强技术等，可以进一步提升模型的泛化能力。最后，探索传统方法与深度学习方法的融合策略，通过结合 DGFMDM 的特征提取能力和 CCNN 的分类能力，实现优势互补。

参考文献

- [1] Kai Keng Ang, Zheng Yang Chin, Haihong Zhang, and Cuntai Guan. Filter bank common spatial pattern (fbcs) in brain-computer interface. In *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*, pages 2390–2397. IEEE, 2008.
- [2] Pinar Civicioglu. Backtracking search optimization algorithm for numerical optimization problems. *Applied Mathematics and computation*, 219(15):8121–8144, 2013.
- [3] Marco Congedo, Pedro Luiz Coelho Rodrigues, and Christian Jutten. The riemannian minimum distance to means field classifier. In *BCI 2019-8th International Brain-Computer Interface Conference*, 2019.
- [4] Ronald A Fisher. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, 7(2):179–188, 1936.
- [5] Yukihiro Hara. Brain plasticity and rehabilitation in stroke patients. *Journal of Nippon Medical School*, 82(1):4–13, 2015.
- [6] Haijie Liu, Penghu Wei, Haochong Wang, Xiaodong Lv, Wei Duan, Meijie Li, Yan Zhao, Qingmei Wang, Xinyuan Chen, Gaige Shi, et al. An eeg motor imagery dataset for brain computer interface in acute stroke patients. *Scientific Data*, 11(1):131, 2024.

- [7] Derek A Pisner and David M Schnyer. Support vector machine. In *Machine learning*, pages 101–121. Elsevier, 2020.
- [8] Claudia Sannelli, Carmen Vidaurre, Klaus-Robert Müller, and Benjamin Blankertz. Common spatial pattern patches-an optimized filter ensemble for adaptive brain-computer interfaces. In *2010 Annual International Conference of the IEEE Engineering in Medicine and Biology*, pages 4351–4354. IEEE, 2010.
- [9] Nikhil Sharma, Joseph Classen, and Leonardo G Cohen. Neural plasticity and its contribution to functional recovery. *Handbook of clinical neurology*, 110:3–12, 2013.
- [10] Yilong Yang, Qingfeng Wu, Yazhen Fu, and Xiaowei Chen. Continuous convolutional neural network with 3d input for eeg-based emotion recognition. In *Neural Information Processing: 25th International Conference, ICONIP 2018, Siem Reap, Cambodia, December 13–16, 2018, Proceedings, Part VII 25*, pages 433–443. Springer, 2018.
- [11] Zhenyue Zhang and Hongyuan Zha. Principal manifolds and nonlinear dimensionality reduction via tangent space alignment. *SIAM journal on scientific computing*, 26(1):313–338, 2004.